

网络化系统的学习与控制

井冈山¹, 王 龙^{2†}, 史大威³, 陈通文⁴

(1. 重庆大学 自动化学院, 重庆 400044; 2. 北京大学 系统与控制研究中心, 北京 100871;

3. 北京理工大学 自动化学院, 北京 100081; 4. 阿尔伯塔大学 电气与计算机工程系, 埃德蒙顿 T6G1H9, 加拿大)

摘要: 网络化系统是指由多个具有交互和任务执行能力的子系统基于网络结构连接而成的动态系统. 由于在不同应用场景中经常呈现高维、多约束、非凸、非线性等特点, 网络化系统的分析与控制问题在本世纪受到了来自不同领域的广泛关注. 为应对动态环境与复杂系统中的不确定性等问题, 具有端到端特性的强化学习方法被引入到网络化系统的控制策略学习中. 然而, 网络化系统的高维数与结构化特性使强化学习的效率和有效性面临严峻挑战. 事实上, 许多研究发现, 网络化系统的性能与其网络结构密切相关, 从图的角度切入能够把复杂的控制问题转化为简单的组合优化问题, 进而实现对实际大规模网络的应用. 鉴于此, 本文从图的视角出发, 对基于学习的网络化系统控制方法做系统性梳理, 通过考察线性二次调节与马尔可夫博弈两种模型下的最优控制问题, 揭示图结构在网络化系统控制策略学习中的重要作用, 同时也将列举该领域现存的难题并展望未来的发展方向.

关键词: 网络化系统; 强化学习; 数据驱动控制; 分布式控制

引用格式: 井冈山, 王龙, 史大威, 等. 网络化系统的学习与控制. 控制理论与应用, 2025, 42(11): 2100 – 2113

DOI: 10.7641/CTA.2025.50259

Learning and control for networked systems

JING Gang-shan¹, WANG Long^{2†}, SHI Da-wei³, CHEN Tong-wen⁴

(1. School of Automation, Chongqing University, Chongqing 400044, China;

2. Center for Systems and Control, Peking University, Beijing 100871, China;

3. School of Automation, Beijing Institute of Technology, Beijing 100081, China;

4. Department of Electrical and Computer Engineering, University of Alberta, Edmonton T6G1H9, Canada)

Abstract: A networked system refers to a system composed of multiple subsystems with the capability of interaction and task execution, connected through a network. Due to the properties of high dimension, multiple constraints, non-convexity, and nonlinearity in various application scenarios, the analysis and control of networked systems have received widespread attention from different communities in this century. To address uncertainties in dynamic environments and complex systems, end-to-end methods like reinforcement learning have been introduced to learn control policies of networked systems. However, the high-dimensional nature of networked systems poses significant challenges to the learning efficiency. In fact, many studies have found that the performance of networked systems is often closely related to the network structures. By approaching the problem from a graph perspective, complex optimization and control problems can be transformed into simple combinatorial optimization problems, enabling the scalability of the method to practical large-scale networks. In light of this, this paper systematically reviews learning-based control methods for networked systems from the graph perspective. By examining optimal control problems formulated by linear quadratic regulation and Markov games, respectively, it highlights the critical role of graph structures in learning control policies for networked systems. Additionally, some challenges in this field are outlined and a prospective outlook on future directions is provided.

Key words: networked systems; reinforcement learning; data-driven control; distributed control

Citation: JING Gangshan, WANG Long, SHI Dawei, et al. Learning and control for networked systems. *Control Theory & Applications*, 2025, 42(11): 2100 – 2113

收稿日期: 2025-06-24; 录用日期: 2025-09-02.

†通信作者. E-mail: longwang@pku.edu.cn.

本文责任编辑: 王凌.

国家自然科学基金项目(62203073, 62533002, 62036002), 重庆市自然科学基金面上项目(CSTB2022NSCQ-MSX0577)资助.

Supported by the National Natural Science Foundation of China (62203073, 62533002, 62036002) and the Natural Science Foundation of Chongqing (CSTB2022NSCQ-MSX0577).

1 引言

网络化系统(networked systems)是由多个具有一定感知、计算、执行和通信能力的子系统组成的集合,其中每个子系统也被称为个体或智能体.自本世纪以来,网络化系统的分布式控制成为控制领域最热门的课题之一,相关的研究涉及一致性^[1-3]、分布式优化^[4]、编队控制^[5-7]、传感器网络定位^[8]、观念动力学^[9]、演化博弈^[10-13]等不同方向.这些研究关注于针对每个智能体设计基于局部信息的分布式交互机制,使系统整体状态收敛至期望的平衡域.然而,工程领域中的控制问题往往对智能体状态演化过程中的瞬时性能有进一步的需求.在一些应用场景(比如有限区域内的编队控制、能量受限下的协同控制、动态环境下的能源分配问题等)中,只考虑收敛性(稳定性)的控制算法将无法保证系统运行过程中的性能要求.因此,网络化系统的最优控制问题也逐渐受到关注.

与传统单系统不同,网络化系统的最优控制问题需要求解最优的分布式控制器.以线性二次调节(linear quadratic regulator, LQR)问题为例,当面临最优分布式控制问题时,期望的线性控制器需要额外满足结构化约束.而这一约束使LQR问题的解空间具有多个连通分支^[14-15],极大增加了问题的求解难度.近年来,机器学习在决策问题中的成功使其受到许多领域学者的青睐.在控制领域,引入数据驱动方法能够实现仅基于控制系统的输入输出数据来学习期望的控制策略,从而解决复杂环境中系统动力学与环境动态难以建模和分析的问题^[16-19].然而,当人们将学习方法引入网络化系统的最优控制问题中时,网络化系统的高维与结构化特性使强化学习面临可扩展性与最优性两方面的困境,亟需有针对性地提出相应的解决方案.

事实上,在基于模型的分布式控制文献中,人们已经建立了丰富的网络化系统性能与网络拓扑之间的关系.这些结论可以帮助人们设计网络拓扑以实现期望的控制效果,比如设计连通网络以实现一致^[2]、设计刚性网络以实现编队和定位^[6,8]、设计社交网络以实现观念聚合^[9]等.然而,网络化系统的结构化特性在现有的策略学习方法中尚未被充分利用,如何设计网络结构以提升控制策略学习的效率与最优性,尚未得到足够的关注.

本文将从网络化系统中网络结构的图刻画视角出发,对现有网络化系统控制策略学习研究进行系统性梳理和介绍.根据物理意义不同,将网络化系统中存在的图总结为观测图、状态耦合图、协作图、通信图这4种,分别用于刻画智能体之间的局部观测关系、动力学上的耦合关系、合作目标中的协作关系,以及面

向控制或决策的信息交换关系.本文将分别针对基于线性二次调节与马尔可夫博弈模型的网络化系统控制策略学习问题展开介绍,通过总结文献中网络拓扑与算法性能的关系,揭示图结构作为分析与设计工具在该方向未被发掘的潜力.

本文结构设置如下:第2章主要介绍网络化系统控制问题的数学模型及其包含的图类型;第3章阐述基于线性二次调节模型的网络化系统分布式控制学习方法;第4章介绍基于马尔可夫博弈模型的网络化系统分布式控制学习方法;第5章总结该领域的开放性问题并展望未来的发展方向.

2 网络化系统的控制问题

本章介绍网络化系统的相关概念以及控制领域的一些代表性工作.由于针对网络化系统的工作涉及范围极广,本章只介绍与本文最密切相关的一些工作.

2.1 网络化系统的数学模型

考虑由 N 个智能体组成的网络化系统, $\mathcal{V} = \{1, \dots, N\}$ 为智能体的标号集合.每个智能体可以用连续时间或离散时间的线性或非线性动力学方程来描述,不同个体的动力学可能存在或不存在耦合.以连续时间系统¹为例,每个子系统的动力学方程一般可以表示为

$$\dot{x}_i = f_i(x_i, u_i), i = 1, \dots, N, \quad (1)$$

其中: $x_i \in \mathbb{R}^d$ 为个体 i 的状态, d 为个体 i 的状态空间维数, u_i 为需要设计的控制输入, $f_i(\cdot, \cdot)$ 为能够表示个体 i 动力学的二元函数, N 为个体的数量.

进一步地,可以将系统(1)写为向量形式,即

$$\dot{x} = f(x, u), \quad (2)$$

其中 $x = (x_1^T \dots x_N^T)^T \in \mathbb{R}^{dN}$ 为系统的总体状态.

2.2 网络化系统的分布式控制

网络化系统分布式控制的标志性特征是每个智能体只能利用局部信息来设计控制器,以实现全局的控制目标.对于每个个体 i ,一个标准的分布式控制器 u_i 一般满足以下形式:

$$u_i = g_i(x_i, \{x_j\}_{j \in \mathcal{N}_i}), \quad (3)$$

其中: $\mathcal{N}_i$ 为个体 i 能够获取的局部信息所来自的邻居集合; $g_i(\cdot, \cdot)$ 为需要设计的控制器形式,也即关于个体 i 能够获得的所有信息的函数.

相较于传统的单个体系统,网络化系统的镇定问题更为复杂.在传统控制理论中,针对系统(2)的镇定问题是指,设计一个控制输入 $u(x)$,使得

$$\lim_{t \rightarrow \infty} x(t) = 0, \quad (4)$$

而对于网络化系统而言,人们关注于设计分布式控制

¹ 本文所介绍的基于图分析的网络化系统协同学习与控制思想同样适用于离散时间系统.

器,使系统状态收敛至一个流形空间 $\mathcal{M}$ 中,即

$$\lim_{t \rightarrow \infty} x(t) \in \mathcal{M}. \quad (5)$$

如果存在一个非负实值函数 $V(\cdot) : \mathbb{R}^{Nd} \rightarrow \mathbb{R}_{\geq 0}$ 使得 $\{x \in \mathbb{R}^{Nd} | V(x) = 0\} = \mathcal{M}$,则分布式控制问题可以理解为如下优化问题:

$$\begin{aligned} \min_{u \in U_d} V(x_\infty), \\ \text{s.t. } \dot{x}_i = f_i(x_i, u_i), i = 1, \dots, N, \end{aligned} \quad (6)$$

其中 $x_\infty = \lim_{t \rightarrow \infty} x(t)$, U_d 为所有满足形式(3)的分布式控制映射组成的集合.

具体而言,在一致性问题^[2,20]中,设计者希望所有个体的状态能够渐进达成一致,此时

$$\mathcal{M} = \{x \in \mathbb{R}^{Nd} | x_i = x_j, \forall i, j = 1, \dots, N\}, \quad (7)$$

在编队控制问题^[6-7]中,控制目标为所有个体的位置状态能够渐进形成与期望队形一致的形状,即

$$\begin{aligned} \mathcal{M} = \{x \in \mathbb{R}^{Nd} | x = s(I_N \otimes R)x^* + 1_N \otimes \eta, \\ s \in \mathbb{R} \setminus \{0\}, R \in \text{SO}(d), \eta \in \mathbb{R}^d\}, \end{aligned} \quad (8)$$

其中: $x^* = (x_1^{*T} \dots x_N^{*T})^T$ 为一组能够形成期望队形的个体位置状态,‘ $\otimes$ ’代表克罗内克积, $\text{SO}(d)$ 为特殊正交群, s 为尺度变量, R 为旋转矩阵, η 为平移向量.

2.3 网络化系统中的图

不同场景中的网络化系统可能存在不同的个体间耦合或交互关系,本节将从分布式控制的角度梳理网络化系统中存在的不同类型的图,这对于理解本文所强调的基于图分析的网络化系统协同控制核心思想具有重要作用.值得注意的是,具体文献中对本节所提到的图的称谓可能不同,但一般不会超出本节所列举的种类.此外,本文所讨论的不同种类的图具有不同的物理意义,因此会以不同的方式融入网络化系统的数学模型.不同图之间不存在包含关系.

在本节讨论的所有图中,总使用集合 $\mathcal{V} = \{1, \dots, N\}$ 代表图中 N 个节点组成的集合,节点 $i \in \mathcal{V}$ 对应于网络化系统中的第 i 个子系统.

2.3.1 观测图

网络化系统通常需要分布式部署在各类场景中,每个子系统会因为感知能力受限而只能获得与邻居个体(而非所有其他个体)之间的相对或绝对信息.用观测图 $\mathcal{G}_O = (\mathcal{V}, \mathcal{E}_O)$ 来描述这种局部观测关系.具体地,如果 $(j, i) \in \mathcal{E}_O$,则观测图 $\mathcal{G}_O$ 中有一条边从节点 j 指向节点 i ,这也意味着个体 i 能够观测到与个体 j 之间的某种相对状态信息 $h_i^O(x_i - x_j)$ 或个体 j 的绝对状态信息 $h_i^O(x_j)$.基于相对状态信息观测 $\{h_i^O(x_i - x_j)\}_{j \in \mathcal{N}_i^O}$,针对个体 i 的分布式控制器(3)可以被表示

为以下形式:

$$u_i = g_i(\{h_i^O(x_i - x_j)\}_{j \in \mathcal{N}_i^O}), \quad (9)$$

其中 $\mathcal{N}_i^O = \{j \in \mathcal{V} | (j, i) \in \mathcal{E}_O\}$ 代表个体 i 在观测图 $\mathcal{G}_O$ 中的邻居集合.

如果个体观测信息为来自邻居的绝对状态信息,则式(9)一般被替换为

$$u_i = g_i(x_i, \{h_i^O(x_j)\}_{j \in \mathcal{N}_i^O}). \quad (10)$$

在编队控制中,根据携带传感器种类的不同,个体 i 能从邻居个体 j 处测得的信息可能是相对位置 $x_i - x_j$ ^[21]、相对距离 $\|x_i - x_j\|$ ^[22]、相对方向 $\frac{x_i - x_j}{\|x_i - x_j\|}$ ^[23]等.

2.3.2 状态耦合图

特定场景中的网络化系统存在子系统之间固定或时变的耦合结构,每个子系统的状态演化会受到其他子系统状态的影响.本文用状态耦合图 $\mathcal{G}_S = (\mathcal{V}, \mathcal{E}_S)$ 来描述这种个体间的状态耦合关系.具体地,如果 $(j, i) \in \mathcal{E}_S$,则状态耦合图 $\mathcal{G}_S$ 中有一条边从节点 j 指向节点 i ,这也意味着个体 i 的状态演化受到个体 j 状态的影响.以连续时间系统为例,本文将个体 i 的动力学行为表示为

$$\dot{x}_i = f_i(x_i, \{x_j\}_{j \in \mathcal{N}_i^S}, u_i), \quad (11)$$

其中 $\mathcal{N}_i^S = \{j \in \mathcal{V} | (j, i) \in \mathcal{E}_S\}$ 代表个体 i 在状态耦合图 $\mathcal{G}_S$ 中的邻居集合.

状态耦合图广泛存在于传染病网络^[24]、资源调度^[25]、交通管控与电力网络^[26]等场景中.由于这种耦合结构的存在,即使不同个体拥有完全独立的控制目标,它们也必须找到一种协作机制来利用或抵消个体之间由耦合导致的相互影响.在无人车编队场景中,除有限运动空间可能带来的个体之间的安全约束以外,一般不同无人车之间不存在位置状态的耦合.然而,一旦给部分无人车之间连上绳索,它们的位置状态将产生耦合.

2.3.3 协作图

网络化系统的协同控制目标一般由人为设定,引入协作图将提供一个全局任务目标的分解方式,进而有利于高效分布式学习或控制算法的设计.在网络结构明显且固定的场景(如交通灯控制、能源网络资源分配)中,不同个体在协同控制目标中的协作关系可以用协作图 $\mathcal{G}_R = (\mathcal{V}, \mathcal{E}_R)$ 来刻画.具体地,如果 $(i, j) \in \mathcal{E}_R$,则协作图中节点 i 与节点 j 之间有一条无向边,这也意味着个体 i 与 j 之间需要合作实现某项控制目标.此时,网络化系统的协作目标可以理解优化一个可分的全局目标函数,即

$$V(x) = \sum_{(i,j) \in \mathcal{E}_R} V_{ij}(x_i, x_j, u_i, u_j), \quad (12)$$

其中 $V_{ij}(x_i, x_j, u_i, u_j) \geq 0$ 为图 $\mathcal{G}_R$ 上的一对邻居 i 和 j 需要协同优化的目标。

值得注意的是, 从全局的任务刻画来看, 协作图一般以无向图的形式出现, 因为这里的一条边仅代表某个任务需要 2 个个体协作完成, 不需要区分协作的方向。然而, 在分布式的网络化系统控制或决策场景中, 控制目标 V_{ij} 可以只分配给个体 i 或个体 j (取决于具体场景中个体的任务执行能力), 从而使协作图成为有向图。

在基于距离约束的编队控制问题中, 期望队形可以由一个刚性图来描述, 一般被称为编队图, 此时, 控制目标中的局部目标函数为

$$V_{ij} = (\|x_i - x_j\|^2 - D_{ij}^2)^2, \quad (13)$$

其中 $D_{ij} > 0$ 为期望队形中个体 i 与 j 之间的距离。

2.3.4 通信图

通信是网络化信息物理系统非常重要的组成部分, 在众多应用场景中扮演着关键角色。本文使用通信图 $\mathcal{G}_C = (\mathcal{V}, \mathcal{E}_C)$ 来描述网络上个体之间的通信关系。具体地, 如果 $(j, i) \in \mathcal{E}_C$, 则通信图中有一条有向边从 j 指向 i , 也即个体 i 能够通过通信接收到从个体 j 处传来的信息。这种信息可能是个体 j 观测到的部分系统状态、输出、或性能, 既可以被用于个体控制策略的学习, 也可以被当作反馈量指导控制信号的生成。

现有许多文献对通信图与观测图的区分并不清晰, 这里简单列举它们之间的区别:

1) 对于每个个体 i , 其观测到的与邻居有关的信息 h_i^O 依赖于自身配置的传感器, 而其基于通信得到的其他邻居个体的信息 h_j^C 取决于其邻居个体拥有的信息;

2) 观测图所依赖的传感器设备主要用于测量实际场景中的物理量, 而个体间通信所依赖的通信模块主要用于传输个体拥有的信息。

因此, 网络化系统使用通信的优势在于能够实现信息共享并扩充每个智能体可使用的信息。与此同时, 相较于信息感知所需要的本地数据采集与处理, 通信由于依赖于网络传输, 更容易出现数据丢包^[27]、有限带宽^[28]、隐私风险等问题。在分布式优化与估计问题^[4]中, 智能体之间的通信(信息交换)对解决协同问题至关重要。而在分布式编队控制问题^[5-7]中, 人们希望智能体仅通过相对观测实现协同, 因为在许多应用场景(如强电磁干扰、地下、水下等环境)中, 个体的通信能力可能受到极大限制。

在本文对具体文献的介绍中, 观测图作为分布式控制约束的图刻画一直存在, 而本节中其他类型的图不一定存在, 如果不提某一类图, 则默认其为完全图。

2.4 网络化系统的最优控制

类似于经典的最优控制问题, 网络化系统的瞬态性能优化也得到了许多关注, 比如在演化轨迹、收敛速度、控制能量方面的优化^[29-30]。

基于第 2.3 节中介绍的 4 种图, 以连续时间系统的无穷时间最优控制为例, 本文建立如下网络化系统的最优控制模型:

$$\begin{aligned} \min_u \quad & \int_0^\infty V(x(t), u(t)) dt, \\ \text{s.t.} \quad & \dot{x}_i = f_i(x_i, \{x_j\}_{j \in \mathcal{N}_i^S}, u_i), \\ & u_i = g_i(x_i, \{x_j\}_{j \in \mathcal{N}_i^O}), \end{aligned} \quad (14)$$

其中:

$$V(x(t), u(t)) = \sum_{(i,j) \in \mathcal{E}_R} V_{ij}(x_i(t), x_j(t)) + \sum_{i \in \mathcal{V}} W_i(u_i(t)) \quad (15)$$

为 t 时刻需要被优化的系统瞬态性能, $V_{ij}(x_i(t), x_j(t)) \geq 0$ 与 $W_i(u_i(t)) \geq 0$ 分别对应于邻居个体间的合作控制目标以及每个智能体的控制能量优化目标。

注意到, 如果

$$\{x \in \mathbb{R}^{Nd} \mid \sum_{(i,j) \in \mathcal{E}_R} V_{ij}(x_i, x_j) = 0\} = \mathcal{M}, \quad (16)$$

其中 $\mathcal{M}$ 为控制目标所对应的期望流形, 则最优控制问题(14)的任意全局或局部最优解均为一个能满足镇定控制目标的分布式控制器。

最优控制问题可以被看作带瞬态性能优化的控制问题, 也可以被理解为带有动力学方程约束的优化问题。如果将动力学系统理解为对动态环境的建模, 最优控制问题便成了动态环境下的决策问题, 也即强化学习方法主要面向的问题。因此, 从最优控制问题切入, 人们容易建立起强化学习与控制问题的桥梁, 这也是目前数据驱动控制文献中大多考虑最优控制问题的原因。

2.5 基于学习的网络化系统控制

现有文献中关于网络化系统分布式控制的工作不胜枚举, 但大多基于简单的线性系统模型或精确的非线性系统模型。当面临系统模型存在随机性或不易精确获取的情况时, 尚不存在令人满意的解决方案。近年来, 强化学习作为一种端到端的数据驱动方法, 在解决动态环境中的决策问题时展现出显著的优势。尤其是在动态环境难以建模的情况下, 端到端的方法可以避免建模问题而直接求得最优策略。注意到, 控制系统也可以被认为是一种动态环境, 因此, 强化学习可以用于在系统建模难度高的场景下实现无模型的最优控制策略求解。近 10 年来, 控制期刊与会议中涌现出了大量的相关文献^[17]。接下来, 本文将分别从“线性二次调节”与“马尔可夫博弈”两种数学模型的视角,

介绍当前网络化系统的控制策略学习工作.

3 基于线性二次调节的网络化系统控制策略学习

对于单系统线性最优控制问题,图1展示了基于策略迭代的学习框架.具体地,令 $u(x) = Kx$ 为从反馈的状态信息到控制信号的映射,本文将 K 称为控制策略.在第 k 轮学习中,对系统不断输入控制信号 $u^k(t) = K^k x(t), t = 0, 1, \dots$,学习算法通过观测系统性能来将策略更新为 K^{k+1} ,以此循环,直至控制策略收敛至 K^* .该框架不需要对系统做建模,直接通过观测到的系统性能信息来指导策略更新,因此可以被理解作为一种强化学习方法.尽管对于一般的非线性系统最优控制问题,强化学习总可以基于策略迭代或值迭代给出数据驱动的求解方法,但一般难以得到带有严格理论保证的最优解.而线性二次调节(LQR)问题由于模型的特殊性,具有诸多优美的性质,针对LQR问题做分析可以得到学习算法的多方面理论结果.




图1 单个控制系统的最佳控制策略学习

Fig. 1 Learning the optimal control policy of a single control system

面向LQR的强化学习存在状态反馈^[31]与输出反馈^[32]两种情况,本文主要探讨图结构对网络化系统控制策略学习的影响,将不专门讨论输出反馈的情况.

3.1 单系统的LQR学习

以连续时间系统为例,单系统的无穷时间LQR问题可以表示如下:

$$\begin{aligned} \min_u J(x(0), u) &:= \int_0^\infty (x^T Q x + u^T R u) dt, \\ \text{s.t. } \dot{x}(t) &= A x(t) + B u(t), \end{aligned} \quad (17)$$

其中: $x(t)$ 和 $u(t)$ 分别为 t 时刻的系统状态和控制输入, A 与 B 分别为系统矩阵与输入矩阵, Q 和 R 分别是半正定矩阵和正定矩阵,二者共同决定了性能指标 J .在无穷时间的LQR问题(17)中,最优控制策略呈线性形式^[33]: $u^* = K^* x$.因此,只需求解最优的控制增益矩阵 K^* 即可.文献[34–35]发现,传统的黎卡提方程求解方法本质上是一种梯度下降方法,因此可以转化为基于策略梯度的学习方法^[31,36].在文献[37]中,作者证明了LQR问题的梯度占优特性,揭示了该特性对于保证策略梯度方法收敛至全局最优解的核心作用.具体地,考虑系统初始状态服从分布 $\mathcal{D}$,对初始状态取期望后LQR问题的性能指标只与线性控制器 K 有关.

则原始LQR问题(17)可以写为如下优化问题:

$$\min_K \bar{J}(K) := E_{x(0) \sim \mathcal{D}} [J(x(0), K)], \quad (18)$$

其中 $\bar{J}(K)$ 表示的瞬态性能累积包含了系统状态与控制输入的关系,因此不再需要呈现动力学约束.进而,人们可以给出针对无约束优化问题(18)的策略梯度算法,即

$$K^{k+1} = K^k - \eta \nabla_K \bar{J}(K^k), \quad (19)$$

其中 k 为学习算法迭代步数, $\eta > 0$ 为迭代步长.

基于梯度占优特性^[37],当初始的控制增益 K^0 对应于一个镇定控制器(stabilizing controller),且 η 在特定范围内时,算法(19)将渐进收敛至式(18)的全局最优解.

进一步地,在文献[38]中,作者考虑了一般的马尔可夫决策过程(Markov decision process, MDP),给出了一般MDP满足梯度占优特性所需要的充分条件.注意到,针对连续状态空间和动作空间的MDP,强化学习方法很难在理论上得到全局最优性保证.然而,作为特殊的具有连续状态与动作空间的MDP,连续时间和离散时间的LQR问题却可以被证明能够基于策略梯度方法得到全局最优控制策略,这进一步反映了LQR问题在理论上的优越性.

3.2 带折扣因子的LQR问题

强化学习所考虑的无穷时间MDP问题一般引入折扣因子来定义累积回报.从实用角度讲,折扣因子能够模拟现实中的时间价值,在考虑长期收益的同时更重视近期收益;从理论角度看,折扣因子的引入能够放宽系统长期性能累积有界的条件,从而促进学习算法的收敛.基于该思想,许多文献在LQR学习问题中也引入了折扣因子,从而放宽策略梯度算法(19)对初始控制器 K_0 的要求.以离散系统的无穷时间LQR问题为例,即

$$\begin{aligned} \min_K \bar{J}(K) &:= \\ E_{x(0) \sim \mathcal{D}} &[\sum_{t=0}^{\infty} \gamma^t x^T(t) (Q + K^T R K) x(t)], \\ \text{s.t. } x(t+1) &= (A + B K) x(t), \end{aligned} \quad (20)$$

其中 $\gamma \in (0, 1]$ 为折扣因子.

针对问题(20), $\bar{J}(K)$ 有界只需 K 能镇定离散系统 $(\sqrt{\gamma}A, \sqrt{\gamma}B)$,也即 $\sqrt{\gamma}(A + BK)$ 舒尔稳定(Schur stable).

类似地,具有折扣因子的连续系统无穷时间LQR问题可以写为

$$\begin{aligned} \min_K \bar{J}(K) &:= \\ E_{x(0) \sim \mathcal{D}} &[\int_{t=0}^{\infty} e^{-\alpha t} x^T (Q + K^T R K) x dt], \\ \text{s.t. } \dot{x}(t) &= (A + B K) x(t), \end{aligned} \quad (21)$$

其中 $\alpha \in [0, \infty)$ 被称为衰减系数, $e^{-\alpha} \in (0, 1]$ 可以起到离散系统中 γ 的作用.

对于问题 (21), $\bar{J}(K)$ 有界只需 K 能镇定连续系统 $(A - \frac{\alpha}{2}I, B)$, 也即 $A - \frac{\alpha}{2}I + BK$ 是赫尔维兹(Hurwitz)的.

3.3 网络化系统的LQR学习

对于网络化系统而言, LQR 问题的主要难点在于需要设计分布式控制器, 以满足网络化系统中每个子系统的观测受限约束. 对于线性控制器, 其分布式特性可以转化为对最优控制增益矩阵 K 的结构化约束, 该约束导致单系统 LQR 问题的梯度占优特性不复存在. 在不考虑第 2.3 节除观测图以外其他图的情况下, 对于一般 LQR 问题, 具有结构化约束的控制增益 K 所处空间的连通分支数量较多, 且在特定情况下随网络规模的增大呈指数增长^[14-15]. 尽管如此, 由于网络化系统独特的性质以及丰富的应用场景, 针对网络化系统的 LQR 问题仍然拥有巨大的研究空间.

本文可以将网络化系统的最优控制问题(14)改写为如下的线性二次调节形式:

$$\begin{aligned} \min_K \bar{J}(K) &:= E_{x(0) \sim \mathcal{D}} \left[\int_0^\infty (x^T Q x + u^T R u) dt \right], \\ \text{s.t. } \dot{x}_i &= \sum_{j \in \mathcal{N}_i^{\mathcal{P}} \cup \{i\}} A_{ij} x_j + B_i u_i, \\ u_i &= \sum_{j \in \mathcal{N}_i^{\mathcal{O}} \cup \{i\}} K_{ij} x_j, i = 1, \dots, N, \end{aligned} \quad (22)$$

其中: $A = [A_{ij}] \in \mathbb{R}^{Nd \times Nd}$ 和 $B = \text{diag}\{B_1, \dots, B_N\} \in \mathbb{R}^{Nd \times Nm}$ 分别为系统的状态矩阵与输入矩阵; $K = [K_{ij}] \in \mathbb{R}^{Nm \times Nd}$ 为需要设计的控制增益矩阵; $Q \in \mathbb{R}^{Nd \times Nd}$ 与 $R \in \mathbb{R}^{Nm \times Nm}$ 分别为半正定矩阵和正定矩阵, 是性能指标中人为设计的参数矩阵, 用于刻画期望优化的网络化系统的瞬态性能.

基于学习的网络化系统最优控制问题主要难点在于以下两点:

1) 可扩展性: 基于学习的控制方法一般需要收集足够的数据以充分刻画系统的特性. 随着网络规模增大, 网络化系统的状态与动作空间的维数迅速增长, 对应的学习方法可能面临数据量需求指数上升(维数灾难)的挑战, 从而使学习效率迅速下降;

2) 最优性: 由于网络化系统对于决策与控制的分分布式需求, 每个子系统只能观测到局部信息. 在全局信息缺失的情况下, 一方面, 智能体学习到的基于局部观测的控制策略很难保证是最优的; 另一方面, 最优的局部观测控制策略与最优的全局观测控制策略所对应的系统性能差别也可能是巨大的.

当在不同场景中以不同形式考虑第 2.3 节中的各类图时, 网络化系统的性能将可以通过调整图结构来得到优化. 接下来, 本章将从“集中式学习”和“分布式

学习”两方面对现有网络化系统的分布式 LQR 学习研究做介绍.

3.4 分布式LQR的集中式学习

集中式学习是指设计者已知网络上所有智能体的输入与状态数据信息, 集中学习最优的所有个体控制器. 图 2 给出了一般的集中式 LQR 学习流程.




图 2 网络化系统最优控制策略的集中式学习

Fig. 2 Centralized learning for seeking the optimal control policy of a networked system

从优化角度来看, 最优分布式控制问题可以写为

$$\begin{aligned} \min_K \bar{J}(K), \\ \text{s.t. } K \in \mathcal{S}_K(\mathcal{G}_O), \end{aligned} \quad (23)$$

其中

$$\begin{aligned} \mathcal{S}_K(\mathcal{G}_O) = \\ \{M \in \mathbb{R}^{Nm \times Nd} | M(i, j) = 0, \forall (i, j) \notin \mathcal{E}_O\}, \end{aligned} \quad (24)$$

而 $M(i, j) \in \mathbb{R}^{m \times d}$ 为矩阵 M 中由第 $im+1 : (i+1)m$ 行与第 $jd+1 : (j+1)d$ 列组成的子矩阵.

集中式学习最优分布式 LQR 的问题可以理解为: 已知性能指标 $J(x(0), K)$ 中的参数矩阵 Q 与 R 以及结构化约束 $\mathcal{S}_K(\mathcal{G}_O)$, 如何设计一系列的控制策略 $\{u(t)\}_{t=0}^T$, 根据观测出的 $\{x(t)\}_{t=0}^T$ 来求解最优的控制增益 $K^* \in \mathcal{S}_K(\mathcal{G}_O)$, 使性能指标达到最优?

3.4.1 分布式镇定控制器学习

系统稳定是一个控制器能实现系统性能最优的必要条件, 在性能指标不存在折扣因子的情况下, 针对 LQR 的学习方法一般需要初始控制器能够镇定系统. 因此, 对于网络化系统而言, 寻找一个分布式镇定控制器至关重要.

尽管一般网络化系统的镇定问题较为复杂, 现有文献对于以一般流形为收敛目标的网络化系统的最优控制问题讨论很少, 更多时候是把面向流形的镇定问题转化为面向原点的镇定问题. 因此, 本文仍然只讨论平衡域为原点的网络化系统最优控制问题.

学习分布式镇定控制器的问题不涉及对某一目标函数的优化, 因此可以理解为一个可行性问题, 即

$$\text{find } K, \quad (25)$$

s.t. K 使系统稳定, (26)

$K \in \mathcal{S}_K(\mathcal{G}_O)$, (27)

其中 $\mathcal{S}_K(\mathcal{G}_O)$ 为结构化约束(24).

对于离散时间系统,代入线性控制器的闭环系统表达式可以写为

$$x(t+1) = (A + BK)x(t), \quad (28)$$

因此,约束(26)等价于 $\rho(A + BK) < 1$,文献[39]首次给出了基于动态折扣因子的单系统镇定控制器数据驱动学习方法,文献[40]进一步考虑了网络化系统场景下具有结构化约束(27)的镇定控制器学习方法.

对于连续时间系统,代入线性控制器的闭环系统表达式为

$$\dot{x}(t) = (A + BK)x(t), \quad (29)$$

此时,约束(26)等价于要求矩阵 $A + BK$ 是赫尔维茨的.文献[41]首次给出了连续时间单系统镇定控制器的学习方法,同时基于半定规划给出了满足结构化约束(27)的镇定控制器学习方法.

3.4.2 最优分布式控制器学习

前面提到,结构化约束下LQR问题的梯度占优特性消失,且局部最优解的数量随系统规模增大而呈指数型增长^[14].尽管如此,文献[42]发现,在结构化约束满足特定条件时,基于输出反馈的LQR问题拥有局部梯度占优特性,因此可以基于集中式策略梯度方法学习到最优的分布式控制器.然而,大部分的分布式控制问题并不满足梯度占优特性,寻找次优解成为许多文献的目标.

为使用策略梯度法求解带约束的优化问题(23),可以将结构化约束融入目标函数.具体地,引入映射 $\mathcal{F}: \mathcal{S}_K(\mathcal{G}_O) \rightarrow \mathbb{R}^q$ 将 $\mathcal{S}_K(\mathcal{G}_O)$ 中任意矩阵中需要更新的元素重新排列为一个向量,其中 $q = (|\mathcal{E}_O| + N)md$ 为向量的维数.不难看出, $\mathcal{F}$ 为一个双射.也即,对于任意 $K \in \mathcal{S}_K(\mathcal{G}_O)$,都有唯一的 $\mathbf{K} \in \mathbb{R}^q$,使得 $\mathbf{K} = \mathcal{F}(K)$ 且 $K = \mathcal{F}^{-1}(\mathbf{K})$.因此,在后文中,笔者也将向量形式的 $\mathbf{K}$ 称为控制器.同时,式(23)可以被改写为一个无约束的优化问题,即

$$\min_{\mathbf{K}} \bar{J}(\mathcal{F}^{-1}(\mathbf{K})), \quad (30)$$

因此,可以给出如下策略梯度方法:

$$\mathbf{K}^{k+1} = \mathbf{K}^k - \eta \nabla_{\mathbf{K}}(\bar{J}(\mathcal{F}^{-1}(\mathbf{K}^k))). \quad (31)$$

当初始控制器 $\mathbf{K}^0$ 使系统稳定且迭代步长 η 满足特定条件时,式(31)将收敛至 $\bar{J}$ 的驻点.注意到,该驻点可能是一个最优或次优解,也可能两者均不是^[43].

3.5 分布式LQR的分布式学习

大部分网络化系统中的子系统只能获取部分其他子系统的信息,这一点不仅体现在控制方案的实施中,

也可能体现在学习的过程中.在现实世界,智能交通^[26]、电力网络^[44]、仓储物流^[45]等场景都展示了对分布式决策的重要需求.因此,分布式LQR的分布式学习也受到了控制领域的广泛关注.图3展示了分布式学习最优控制器的基本思路,其中网络化系统整体的控制增益被分成了 N 个智能体的个体增益: $\mathbf{K} = (\mathbf{K}_1^T \cdots \mathbf{K}_N^T)^T$, $\mathbf{K}_i$ 为第 i 个智能体的控制增益.可以看出,分布式学习的主要特点在于每个智能体将运行各自的学习算法,基于收集的局部信息来学习最优的个体控制策略.




图3 网络化系统最优控制策略的分布式学习

Fig. 3 Distributed learning for seeking the optimal control policy of a networked system

3.5.1 基于一致性的分布式学习

受到分布式优化^[46-47]方法的启发,利用一致性算法实现全局信息估计成为一个主流的解决分布式学习问题的思路^[43].具体地,在分布式学习场景中,全局性能可以写为局部性能的平均,即

$$\bar{J}(\mathcal{F}^{-1}(\mathbf{K})) = \frac{1}{N} \sum_{i=1}^N \tilde{J}_i(\mathbf{K}), \quad (32)$$

其中 $\tilde{J}_i(\mathbf{K})$ 为个体 i 观测到的基于控制器 $\mathbf{K}$ 的局部性能.

基于一致性的分布式策略梯度学习算法可以表示为

$$\mathbf{K}_i^{k+1} = \mathbf{K}_i^k - \eta G_i(\mathbf{K}^k), \quad (33)$$

其中 $\mathbf{K}_i^k$ 为学习到第 k 步时智能体 i 的策略变量,也即全局控制器 $\mathbf{K}$ 的一部分: $\mathbf{K} = (\mathbf{K}_1^T \cdots \mathbf{K}_N^T)^T$, $G_i(\mathbf{K}^k)$ 为对 $\nabla_{\mathbf{K}_i}(\bar{J}(\mathcal{F}^{-1}(\mathbf{K}^k)))$ 的估计.

注意到,梯度估计一般只需要获取给定控制器下的系统全局性能信息.因此,个体 i 只需通过与邻居交换各自观测的局部性能来估计全局性能,就可以算出 $G_i(\mathbf{K})$.而经典的平均一致性算法就可以实现这一目标:

$$\hat{J}_i(s+1) = \sum_{j \in \mathcal{N}_i \cup \{i\}} W_{ij} \hat{J}_j(s), \quad (34)$$

其中 $\hat{J}_i$ 为个体 i 对于全局观测的估计, $[W_{ij}]$ 是双随机矩阵.一旦设置 $\hat{J}_i(0) = \tilde{J}_i(\mathbf{K})$,且通信图是连通的,

则所有个体将渐进估计到全局的系统性能, 即

$$\lim_{s \rightarrow \infty} \hat{J}_i(s) = \frac{1}{N} \sum_{i=1}^N \tilde{J}_i(\mathbf{K}), \quad i = 1, \dots, N. \quad (35)$$

基于一致性的分布式学习方法能够应对具有任意观测图、状态耦合图、以及协作图的网络化系统 LQR 问题, 且只需要通信图连通。但是, 其同时存在 2 个明显的缺点: 1) 学习算法的每一步迭代依赖于一致性算法的收敛, 而一致性算法随着网络规模增大将收敛的越来越慢; 2) 基于全局性能指标的梯度估计在面临大规模网络时方差很大。具体地, 由于大规模网络中个体的控制策略变化对全局性能的影响很小, 且每个智能体的局部性能观测都存在随机误差, 叠加后会使得全局性能关于个体的梯度估计误差很大, 从而进一步影响学习算法的收敛速度。

3.5.2 基于协作图的分布式学习

基于一致性的分布式学习方法解决了网络化系统中的信息受限问题, 但无法解决(甚至加剧了)面向大规模网络的可扩展性问题。事实上, 文献中对大规模优化问题的求解往往侧重于将原问题等价或近似分解为多个小规模问题, 通过降低变量维数来提高学习效率。在网络化系统的 LQR 学习问题中, 协作图的存在增强了问题本身的结构化特性, 因此能够促进对整体问题的有效分解, 进而显著提升网络化系统分布式学习的可扩展性。

在 LQR 问题(22)的优化目标中, 关于控制器的优化项 $u^T R u$ 一般用于优化系统的累积控制量, 从而节省控制需要的能量。因此, 一般设置 $R = \text{diag}\{R_1, \dots, R_N\} \succ 0$, 即每个智能体优化自身的控制能量。而关于系统状态的优化目标 $x^T Q x$ 通常涉及不同智能体之间的协同关系, 因此, 协作图将在矩阵 Q 中体现。

融合了协作图的矩阵 $Q \succeq 0$ 的一般形式如下:

$$Q = G_R \odot \tilde{Q}, \quad (36)$$

其中: $\odot$ 代表 Khatri-Rao 积, $G_R \in \mathbb{R}^{N \times N} \succeq 0$, $\tilde{Q} \in \mathbb{R}^{nN \times nN}$, $G_R(i, i) \succeq 0$ 对 $i = 1, \dots, N$, $G_R(i, j) = 0$ 对任意 $(i, j) \notin \mathcal{E}_R$ 且 $i \neq j$ 。

在文献[48]中, 在对分布式控制不做要求(观测图可以是完全图)的情况下, 作者基于协作图, 针对所有

个体具有相同动力学行为且无动力学耦合的网络化系统, 实现了学习问题的分解, 提出了分布式的 Q 学习算法使每个智能体学习到自身关于全局性能的最优控制器。

在文献[49]中, 作者基于协作图将整个网络化系统分为多群, 实现了整体 LQR 问题的近似分解。通过分层学习, 算法能够收敛至网络化系统关于全局性能的次优控制器。而协作图结构与分群方式决定了收敛控制器的次优性以及所使用观测图的稀疏性。因此, 分群方式的选取需要权衡控制器的次优性以及分布式程度。在协作图与状态耦合图同时存在且具有同样结构的情况下, 文献[50–51]分析了网络化系统 LQR 问题中控制器次优性与观测图稀疏度的关系。

上一小节中提到, 基于全局性能指标的策略梯度方法存在梯度估计误差大的问题。其核心原因在于个体动作对于网络全局性能的影响较小, 全局性能所包含的冗余信息将增大局部梯度的估计误差。当协作图存在时, 网络化系统的结构特性更加显著, 是否可以从网络化系统中提取局部性能, 使其对个体策略的梯度也能用于面向全局性能的策略更新呢? 要实现这一目标, 需要对每个子系统 i 构造只涉及部分个体的局部目标函数 $\bar{J}_i(\mathbf{K}_i^{\text{sub}})$, 使得

$$\nabla_{\mathbf{K}_i} \bar{J}(\mathcal{F}^{-1}(\mathbf{K})) = \nabla_{\mathbf{K}_i} \bar{J}_i(\mathbf{K}_i^{\text{sub}}), \quad (37)$$

在文献[52]中, 通过分析协作图与观测图的结构, 作者得到了个体策略可能影响的所有个体集合, 从而构建了学习图 $\mathcal{G} = (\mathcal{V}, \mathcal{E}_L)$, 使得 $\bar{J}_i$ 只与个体 i 在学习图中的邻居有关, 且式(37)成立。

式(37)需要局部目标函数 $\bar{J}_i$ 包括所有被个体 i 策略影响的个体奖励, 当协作图与观测图较为稠密时, $\bar{J}_i$ 可能涉及所有个体, 从而与 $\bar{J}$ 相等。在复杂的大规模网络中, 网络化系统的耦合结构错综复杂, 经常出现个体之间互相影响但强度较低的情况, 此时, 通过忽略较弱的影响关系, 式(37)仍然能够近似成立。

表 1 根据动力学类型、学习方式以及对网络结构的图刻画方式汇总了网络化系统 LQR 学习与控制的相关文献, 其中不同类型图刻画下的文献不一定是基于学习的控制方法, 但反映了人们对网络结构在 LQR 问题框架下的不同理解。

表 1 网络化系统 LQR 学习与控制文献汇总

Table 1 A summary of learning and control references related to the LQR problem of networked systems

	集中式学习	分布式学习	状态耦合图	协作图	通信图
连续时间 LQR	文献 [40–41, 53–60]	文献 [49, 61–62]	文献 [41, 57, 60–63]	文献 [49, 63–67]	文献 [49, 61–62]
离散时间 LQR	文献 [42, 68]	文献 [43, 48, 50–52, 69–72]	文献 [51, 70–72]	文献 [48, 50–52, 68–70, 72–73]	文献 [43, 48, 50–52, 69–72]

4 基于马尔可夫博弈的网络化系统控制策略学习

从数学模型来看,网络化系统的最优控制问题是一种特殊的合作马尔可夫博弈(Markov game)问题,因此可以使用多智能体强化学习(multi-agent reinforcement learning, MARL)方法来实现对更一般网络化系统的最优控制策略学习^[74-75].事实上,第2章介绍的网络化系统中的多类图同样存在于具有网络化结构的MDP中.本章将介绍MDP中可能存在的网络结构以及对应的一些强化学习方法.本文将所研究的对象称为网络化马尔可夫决策过程(networked MDP, NMDP).注意到,与文献[24]中强调的网络上的MDP不同,除了智能体在状态演化上的相互耦合关系以外,本章还将引入决策过程中可能存在的其他类型网络结构.

4.1 马尔可夫博弈中的图

首先介绍面向多智能体协同决策的合作马尔可夫博弈的数学模型.考虑元组 $(\mathcal{V}, \mathcal{S}, \mathcal{A}, P, \mathcal{O}, r, \gamma)$,其中:

- 1) $\mathcal{V} = \{1, \dots, N\}$ 表示 N 个智能体的标号集合;
- 2) $\mathcal{S} = \prod_{i \in \mathcal{V}} \mathcal{S}_i$ 为状态空间,其中 $\mathcal{S}_i$ 为智能体 i 的状态空间, $s_i \in \mathcal{S}_i$ 对应于网络化系统(14)中的个体状态 x_i ;
- 3) $\mathcal{A} = \prod_{i \in \mathcal{V}} \mathcal{A}_i$ 为动作空间,其中 $\mathcal{A}_i$ 为智能体 i 的动作空间, $a_i \in \mathcal{A}_i$ 对应于网络化系统(14)中的个体控制器 u_i ;
- 4) $P: \mathcal{S} \times \mathcal{A} \rightarrow \mathcal{P}(\mathcal{S})$ 为环境状态的转移概率,对应于网络化系统的动力学;
- 5) $\mathcal{O} = \prod_{i \in \mathcal{V}} \mathcal{O}_i$ 为观测空间, $\mathcal{O}_i$ 代表智能体 i 的观测空间,对应于网络化系统(14)中智能体 i 可用的与邻居间的局部信息;
- 6) $r: \mathcal{S} \times \mathcal{A} \rightarrow \mathbb{R}$ 为网络化系统的单步总体奖励,对应于网络化系统LQR问题中的瞬态性能;
- 7) $\gamma \in (0, 1)$ 为折扣因子,也对应于离散时间系统LQR(20)中的折扣因子.

合作马尔可夫博弈的总体目标为针对每个智能体设计一个策略 $\pi_i: \mathcal{O}_i \rightarrow \mathcal{P}(\mathcal{A}_i)$,使得如下形式的长期累积奖励(以无穷时间状态值函数为例)最大化:

$$V^\pi(s) = E_{a \sim \pi} \left[\sum_{t=0}^{\infty} \gamma^t r(s^t, a^t) | s^0 = s \right], \quad (38)$$

该目标函数也对应于网络化系统LQR(20)中的目标函数.

类似于网络化系统控制中的图结构,接下来介绍马尔可夫博弈中可能存在的不同种类的图.注意到,下述每种图中所有智能体均有自环,为简便起见,记 $\mathcal{N}_i^X = \{j \in \mathcal{V} : (j, i) \in \mathcal{E}_X\}$ 为智能体 i 在图 $\mathcal{G}_X = (\mathcal{V},$

$\mathcal{E}_X)$ 上的邻居,则总有 $i \in \mathcal{N}_i^X, X \in \{O, S, R, C\}$.

4.1.1 观测图

马尔可夫博弈问题的主要难点在于,每个智能体在面向环境做决策的同时又作为环境的一部分在动态变化,从而影响其他智能体的决策.在大规模网络以及许多应用场景中,每个智能体的局部观测只包括其他部分智能体的状态或动作信息.具体地,本文用观测图 $\mathcal{G}_O = (\mathcal{V}, \mathcal{E}_O)$ 来描述智能体之间的相互观测关系,则智能体 i 的局部观测可以表示为 $\mathcal{O}_i = f(\{s_j, a_j\}_{j \in \mathcal{N}_i^O})$.

4.1.2 状态耦合图

网络化系统中不同智能体的状态演化经常存在耦合,比如在交通网络中,相邻交叉路口的车流量变化会相互影响^[24].本文用状态耦合图 $\mathcal{G}_S = (\mathcal{V}, \mathcal{E}_S)$ 来描述不同智能体之间的状态耦合关系.具体地,智能体 i 从时刻 t 到时刻 $t+1$ 的状态转移概率可以表示为 $P(s_i(t+1) | \{s_j(t)\}_{j \in \mathcal{N}_i^S}, a_i(t))$.

4.1.3 协作图

类似于网络化系统协同控制,合作马尔可夫博弈中所有智能体也拥有一个公共的优化目标.在许多应用场景下,该目标函数是可分的^[76],且组成总体目标函数的每个子函数只与部分个体的动作有关,这种网络化的结构可以为大规模问题的分解与高效求解提供重要线索.具体地,本文用协作图 $\mathcal{G}_R = (\mathcal{V}, \mathcal{E}_R)$ 来描述不同智能体在协同目标中的耦合关系,则总体优化的目标函数可以表示为 $V^\pi(s) = \sum_{i=1}^N V_i^{\{\pi_j\}_{j \in \mathcal{N}_i^R}}(s)$.

4.1.4 通信图

为提高多智能体强化学习的学习效率,引入通信能够实现智能体之间的信息共享与策略协调.因此,与网络化系统控制类似,可以用通信图 $\mathcal{G}_C = (\mathcal{V}, \mathcal{E}_C)$ 来描述智能体之间的通信关系.当 $(j, i) \in \mathcal{E}_C$ 时,智能体 j 可以通过通信向智能体 i 传输状态、动作、奖励信号、策略、经验样本、环境信息等一系列有助于提高学习效率的信息.

从以上描述可以看出,NMDP可以被认为是一种广义的网络化系统最优控制问题.尽管现有的MARL方法以及相关理论结果非常丰富,很多方法并未关注问题中存在的网络结构.本章主要介绍利用图结构来求解NMDP的一些常用方法,这些方法对于解决实际场景中复杂网络化系统控制问题具有重要意义.接下来分为集中式学习与分布式学习来具体介绍.

4.2 分布式控制的集中式学习

集中式学习方法是指中心节点收集到环境的所有信息,并学习所有智能体的最优策略.这类方法适用于环境复杂、需要智能体之间进行高度协调的任务,比如动态资源分配、交通灯协同控制等场景.集中式

学习往往面临状态与动作空间维数过高导致的学习效率低下问题, 而NMDP的网络化特性为提升学习效率提供了重要思路. 接下来介绍两种典型的利用图结构实现的高效集中式学习方法.

4.2.1 基于协作图的值函数分解

MARL中的协作图概念首次在文献[76]中被提出, 主要思想为将全局值函数分解为多个只涉及部分智能体动作的局部值函数, 从而降低训练时的动作搜索空间维数, 提高学习效率. 具体地, 全局状态-动作值函数 Q 可以被表示为

$$Q = \sum_{(i,j) \in \mathcal{E}_R} Q_{ij}(s, a_i, a_j), \quad (39)$$

其中每个局部值函数只与两个智能体有关, 且对应于协作图的一条边.

在传感器网络、风力发电厂、交通灯控制等问题中, 协作图一般可以直接获得. 同时, 许多实际的网络化系统决策场景中协作图结构并不明显, 甚至是关于环境状态动态变化的, 此时也可以基于数据学习智能体之间的协作关系^[77].

4.2.2 基于状态耦合图的截断值函数

当智能体之间存在状态耦合图时, 由于奖励中折扣因子的作用, 每个智能体执行动作后, 对其他智能体奖励的影响呈现关于网络上距离的指数衰减效果^[24]. 具体地, 用 $Q_i(s, a)$ 表示智能体 i 关于其奖励 r_i 的状态-动作值函数, 用 κ 表示截断范围, s_i^κ 与 a_i^κ 表示状态耦合图上与智能体 i 间距离不超过 κ 的智能体的状态与动作集合, $s_i^{\kappa-}$ 与 $a_i^{\kappa-}$ 代表其余智能体的状态与动作集合, 则存在 $c > 0, \rho \in (0, 1)$, 使得对于任意状态 $s' \in \mathcal{S}$ 与动作 $a' \in \mathcal{A}$, 有下式成立:

$$|Q_i(s, a) - Q_i(s_i^\kappa, s_i^{\kappa-}, a_i^\kappa, a_i^{\kappa-})| \leq c\rho^{\kappa+1}, \quad (40)$$

该不等式意味着可以通过忽略网络中距离较远的智能体之间的相互影响, 使用只涉及少数智能体的截断值函数指导策略更新, 从而有效降低状态空间与动作空间的维数.

4.3 分布式控制的分布式学习

分布式学习方法是指每个智能体基于局部观测以及与邻居智能体的通信来学习最优的个体策略, 常用于信息受限的大规模网络决策与控制问题中, 比如大型电力网络的能源调度、大规模交通网络车流量的调控.

4.3.1 基于一致性的分布式学习

一致性算法可以实现智能体对全局信息平均的估计, 因此是解决信息受限问题的有效手段. 在文献[78]与文献[79]中, 基于一致性的全局值函数估计分别被用于Q学习和actor-critic框架下的强化学习. 在文献[80]中, 作者结合一致性算法与残差反馈的零阶梯度给出了分布式策略梯度算法.

以上方法的优势在于仅需通信图连通, 且适用于广泛的信息受限问题. 然而, 类似于基于一致性的LQR分布式学习方法, 面向NMDP的基于一致性的分布式学习方法也存在一些弊端: 1) 需要智能体之间频繁通信, 造成算法运行具有较大通信负担; 2) 算法收敛速度将随着网络规模的增大而显著降低; 3) 基于全局值函数的个体策略随机梯度估计会引起较大方差, 导致算法在面向大规模网络时学习效率大幅降低.

4.3.2 基于图分析的分布式学习

在文献[25]中, 通过同时考虑观测图、状态耦合图、奖励耦合图(与协作图不同, 但可以导出协作图), 作者推导了每个智能体 i 的策略能够影响的所有智能体集合, 并由此构造了局部值函数. 进一步, 作者证明了局部值函数在指导策略更新时与全局值函数的等价性, 因此只需直接使用局部值函数计算梯度来更新策略, 不需要基于一致性的全局信息估计, 这显著降低了梯度估计误差. 然而, 该方法所提供的局部值函数涉及的智能体数量依赖于前述各类图的稀疏性, 在图比较稠密时容易失效. 为解决该问题, 作者进一步引入了值函数截断方法, 通过忽略每个智能体策略对其距离较远个体的影响来进一步简化局部值函数. 该方法有效提升了分布式强化学习的可扩展性, 使算法采样复杂度对网络规模的依赖减弱为对网络结构和截断范围的依赖.

在文献[26]中, 作者提出了基于模型的分布式强化学习方法, 基于状态耦合图结构导致的指数衰减特性构造截断值函数的同时, 进一步引入了模型学习以补偿值函数截断引起的梯度估计误差, 从而提升学习效率.

表2分类总结了文献中不同图与学习机制下面向NMDP模型的研究成果. 与其他多智能体策略梯度算法一样, 以上方法并不能在理论上保证学习算法收敛至最优策略. 目前, 如何学习网络化系统在局部观测下的全局最优控制策略仍然是一个开放性难题.

表 2 面向NMDP的多智能体强化学习文献汇总

Table 1 A summary of multi-agent reinforcement learning references for NMDP

集中式学习	分布式学习	状态耦合图	观测图	协作图	通信图
文献[24, 76–77, 81–91]	文献[25–26, 80, 92–95]	文献[24, 26, 83, 87, 94–95]	文献[25–26, 84–85, 88, 94]	文献[76–77, 82, 86–87, 89, 91–92]	文献[26, 77, 80–81, 85, 88, 90–91, 93, 95]

5 总结与展望

本文总结了网络化系统控制问题中四种网络结构的图刻画方式,从网络结构建模与使用方法的角度对现有文献中网络化系统的控制策略学习方法进行了梳理.总体而言,图刻画是所有网络化系统控制研究中必不可少的一环,但不同场景下的网络化系统对图的建模与使用方法各异.现有文献已得到了许多图结构与网络化系统学习算法性能的关系,但仍然面临学习效率与最优性方面的瓶颈.基于此研究现状,本文主要展望以下5方面的问题:

1) 许多网络化系统控制文献已经考虑了面向一般流形空间的镇定问题,但在网络化系统最优控制学习中,鲜有文献考虑系统稳态非零的镇定控制器.如何学习控制器,在保证系统瞬态性能累积最优的同时,使系统状态收敛至期望的一般流形空间,是一个尚未解决但具有广阔应用前景的研究课题;

2) 目前网络化系统的控制策略学习在可扩展性方面仍面临瓶颈.文献中具有高可扩展性的算法一般需要假设网络拓扑固定且满足特定条件.然而,复杂环境下可能存在切换且未知的网络拓扑.如何学习并应对网络中智能体之间的耦合关系,从而实现对大规模网络的有效分解,是一个富有价值但极具挑战的问题;

3) 网络化系统的最优分布式控制学习仍然是一个开放性问题.即使针对LQR模型,集中式的策略迭代方法也难以收敛至最优分布式控制.然而,现有文献尚未深入研究观测图结构对收敛控制器最优性的影响.如何建立观测图与学习算法最优性之间的关系是一个有趣同时也较为棘手的问题;

4) 对于马尔可夫博弈问题而言,即使假设所有智能体拥有全局观测,要实现全局最优策略的搜索也并不容易.现有研究发现,使用自回归形式的动作依赖策略能够实现全局最优^[96].然而,这种方式的策略学习复杂度较高,难以扩展至大规模网络.如何有效利用网络化系统的结构性质,建立具有稀疏依赖关系同时又保证全局最优性的动作依赖策略,也是未来可以重点考虑的方向;

5) 近年来,由多个体组成基本交互单元的高阶网络被发现能够在许多场景下促进个体间的合作^[13,97-99],在演化博弈领域引起了大量关注.事实上,高阶网络对应于更广义的图结构,可以拓宽本文列举的四种图的形式,这种扩展将能够描述更广义的个体间耦合关系,优化个体间的交互机制,从而提升合作效率.目前,在网络化系统的控制策略学习领域,基于高阶网络的研究仍处于空白阶段,未来将是值得深入探索的重要研究方向.

参考文献:

- [1] JADBABAIE A, LIN J, MORSE A S. Coordination of groups of mobile autonomous agents using nearest neighbor rules. *IEEE Transactions on Automatic Control*, 2003, 48(6): 988 – 1001.
- [2] OLFATI-SABER R, FAX J A, MURRAY R M. Consensus and cooperation in networked multi-agent systems. *Proceedings of the IEEE*, 2007, 95(1): 215 – 233.
- [3] YU J, WANG L. Group consensus in multi-agent systems with switching topologies and communication delays. *Systems & Control Letters*, 2010, 59(6): 340 – 348.
- [4] WANG Long, LU Kaihong, GUAN Yongqiang. Distributed optimization via multi-agent systems. *Control Theory & Applications*, 2019, 36(11): 1820 – 1833.
(王龙, 卢开红, 关永强. 分布式优化的多智能体方法. 控制理论与应用, 2019, 36(11): 1820 – 1833.)
- [5] JING G, ZHANG G, LEE H W J, et al. Weak rigidity theory and its application to formation stabilization. *SIAM Journal on Control and Optimization*, 2018, 56(3): 2248 – 2273.
- [6] JING G, ZHANG G, LEE H W J, et al. Angle-based shape determination theory of planar graphs with application to formation stabilization. *Automatica*, 2019, 105: 117 – 129.
- [7] JING G, WANG L. Multiagent flocking with angle-based formation shape control. *IEEE Transactions on Automatic Control*, 2019, 65(2): 817 – 823.
- [8] JING G, WAN C, DAI R. Angle-based sensor network localization. *IEEE Transactions on Automatic Control*, 2021, 67(2): 840 – 855.
- [9] WANG Long, TIAN Ye, DU Jinming. Opinion dynamics in social networks. *Science China Information Sciences*, 2018, 48(1): 3 – 23.
(王龙, 田野, 杜金铭. 社会网络上的观念动力学. 中国科学: 信息科学, 2018, 48(1): 3 – 23.)
- [10] WANG Long, HUANG Feng. An interdisciplinary survey of multi-agent games, learning, and control. *Acta Automatica Sinica*, 2023, 49(3): 580 – 613.
(王龙, 黄锋. 多智能体博弈, 学习与控制. 自动化学报, 2023, 49(3): 580 – 613.)
- [11] LI A, CORNELIUS S P, LIU Y Y, et al. The fundamental advantages of temporal networks. *Science*, 2017, 358(6366): 1042 – 1046.
- [12] WANG L, FU F, CHEN X. Mathematics of multi-agent learning systems at the interface of game theory and artificial intelligence. *Science China Information Sciences*, 2024, 67(6): 166201.
- [13] SHENG A, SU Q, WANG L, et al. Strategy evolution on higher-order networks. *Nature Computational Science*, 2024, 4(4): 274 – 284.
- [14] FENG H, LAVAEI J. On the exponential number of connected components for the feasible set of optimal decentralized control problems. *American Control Conference (ACC)*. Philadelphia, PA: IEEE, 2019: 1430 – 1437.
- [15] BU J, MESBAHI A, MESBAHI M. On topological properties of the set of stabilizing feedback gains. *IEEE Transactions on Automatic Control*, 2020, 66(2): 730 – 744.
- [16] YU H, GUAN Z, CHEN T, et al. Design of data-driven PID controllers with adaptive updating rules. *Automatica*, 2020, 121: 109185.
- [17] HU B, ZHANG K, LI N, et al. Toward a theoretical foundation of policy optimization for learning control policies. *Annual Review of Control, Robotics, and Autonomous Systems*, 2023, 6(1): 123 – 158.
- [18] DENG L, SHU Z, CHEN T. Event-triggered robust MPC with terminal inequality constraints: A data-driven approach. *IEEE Transactions on Automatic Control*, 2024, 69(7): 4773 – 4780.
- [19] FENG S, SHI D, CHEN T, et al. Data-driven learning and control with event-triggered measurements. *IEEE Transactions on Automatic Control*, 2025, 70(8): 5301 – 5316.

- [20] WANG L, XIAO F. Finite-time consensus problems for networks of dynamic agents. *IEEE Transactions on Automatic Control*, 2010, 55(4): 950 – 955.
- [21] XIAO F, WANG L, CHEN J, et al. Finite-time formation control for multi-agent systems. *Automatica*, 2009, 45(11): 2605 – 2611.
- [22] OH K K, AHN H S. Formation control of mobile agents based on inter-agent distance dynamics. *Automatica*, 2011, 47(10): 2306 – 2312.
- [23] ZHAO S, ZELAZO D. Bearing rigidity and almost global bearing-only formation stabilization. *IEEE Transactions on Automatic Control*, 2015, 61(5): 1255 – 1268.
- [24] QU G, WIERMAN A, LI N. Scalable reinforcement learning for multiagent networked systems. *Operations Research*, 2022, 70(6): 3601 – 3628.
- [25] JING G, BAI H, GEORGE J, et al. Distributed multi-agent reinforcement learning based on graph-induced local value functions. *IEEE Transactions on Automatic Control*, 2024, 69(10): 6636 – 6651.
- [26] MA C, LI A, DU Y, et al. Efficient and scalable reinforcement learning for large-scale network control. *Nature Machine Intelligence*, 2024, 6(9): 1006 – 1020.
- [27] YU M, WANG L, CHU T, et al. Stabilization of networked control systems with data packet dropout and network delays via switching system approach. *IEEE Conference on Decision and Control (CDC)*. Bahamas: IEEE, 2004: 3539 – 3544.
- [28] XIAO F, WANG L. Asynchronous consensus in continuous-time multi-agent systems with switching topology and time-varying delays. *IEEE Transactions on Automatic Control*, 2008, 53(8): 1804 – 1816.
- [29] FODERARO G, FERRARI S, WETTERGREN T A. Distributed optimal control for multi-agent trajectory optimization. *Automatica*, 2014, 50(1): 149 – 154.
- [30] LEWIS F L, ZHANG H, HENGSTER-MOVRIC K, et al. *Cooperative Control of Multi-Agent Systems: Optimal and Adaptive Design Approaches*. London: Springer Science & Business Media, 2013.
- [31] JIANG Y, JIANG Z P. Computational adaptive optimal control for continuous-time linear systems with completely unknown dynamics. *Automatica*, 2012, 48(10): 2699 – 2704.
- [32] GAO W, JIANG Z P. Data-driven adaptive optimal output-feedback control of a 2-DOF helicopter. *American Control Conference (ACC)*. Boston, MA: IEEE, 2016: 2512 – 2517.
- [33] ANDERSON B D, MOORE J B. *Optimal Control: Linear Quadratic Methods*. NJ, USA: Prentice-Hall, Inc., 1990.
- [34] BU J, MESBAHI A, MESBAHI M. Policy gradient-based algorithms for continuous-time linear quadratic control. *ArXiv Preprint*, 2020, arxiv: 2006.09178.
- [35] BU J, MESBAHI A, FAZEL M, et al. LQR through the lens of first order methods: Discrete-time case. *ArXiv Preprint*, 2019, arXiv: 1907.08921.
- [36] LEWIS F L, VRABIE D. Reinforcement learning and adaptive dynamic programming for feedback control. *IEEE Circuits and Systems Magazine*, 2009, 9(3): 32 – 50.
- [37] FAZEL M, GE R, KAKADE S, et al. Global convergence of policy gradient methods for the linear quadratic regulator. *International Conference on Machine Learning*. Stockholm, Sweden: JMLR, 2018: 1467 – 1476.
- [38] AGARWAL A, KAKADE S M, LEE J D, et al. On the theory of policy gradient methods: Optimality, approximation, and distribution shift. *Journal of Machine Learning Research*, 2021, 22(98): 1 – 76.
- [39] LAMPERSKI A. Computing stabilizing linear controllers via policy iteration. *IEEE Conference on Decision and Control (CDC)*. Jeju, Korea(South): IEEE, 2020: 1902 – 1907.
- [40] MUKHERJEE S, VU T L. Reinforcement learning of structured stabilizing control for linear systems with unknown state matrix. *IEEE Transactions on Automatic Control*, 2022, 68(3): 1746 – 1752.
- [41] JING G, BAI H, GEORGE J, et al. Learning distributed stabilizing controllers for multi-agent systems. *IEEE Control Systems Letters*, 2022, 6: 301 – 306.
- [42] FURIERI L, ZHENG Y, KAMGARPOUR M. Learning the globally optimal distributed LQ regulator. *Learning for Dynamics and Control*, 2020: 287 – 297.
- [43] LI Y, TANG Y, ZHANG R, et al. Distributed reinforcement learning for decentralized linear quadratic control: A derivative-free policy optimization approach. *IEEE Transactions on Automatic Control*, 2021, 67(12): 6429 – 6444.
- [44] CHUNG H M, MAHARJAN S, ZHANG Y, et al. Distributed deep reinforcement learning for intelligent load scheduling in residential smart grids. *IEEE Transactions on Industrial Informatics*, 2020, 17(4): 2752 – 2763.
- [45] SHEN Y, MCCLOSKEY B, DURHAM J W, et al. Multi-agent reinforcement learning for resource allocation in large-scale robotic warehouse sortation centers. *IEEE Conference on Decision and Control (CDC)*. Singapore: IEEE, 2023: 7137 – 7143.
- [46] NEDIC A, LIU J. Distributed optimization for control. *Annual Review of Control, Robotics, and Autonomous Systems*, 2018, 1(1): 77 – 103.
- [47] LU K, JING G, WANG L. Distributed algorithms for searching generalized Nash equilibrium of noncooperative games. *IEEE Transactions on Cybernetics*, 2018, 49(6): 2362 – 2371.
- [48] ALEMZADEH S, MESBAHI M. Distributed Q-learning for dynamically decoupled systems. *American Control Conference (ACC)*. Philadelphia, PA: IEEE, 2019: 772 – 777.
- [49] JING G, BAI H, GEORGE J, et al. Model-free optimal control of linear multi-agent systems via decomposition and hierarchical approximation. *IEEE Transactions on Control of Network Systems*, 2021, 8(3): 1069 – 1081.
- [50] SHIN S, LIN Y, QU G, et al. Near-optimal distributed linear-quadratic regulator for networked systems. *SIAM Journal on Control and Optimization*, 2023, 61(3): 1113 – 1135.
- [51] ZHANG R C, LI W, LI N. Optimal network control of spatially exponential decaying linear quadratic regulator. *Automatica*, 2025, 173: 112061.
- [52] JING G, BAI H, GEORGE J, et al. Asynchronous distributed reinforcement learning for LQR control via zeroth-order block coordinate descent. *IEEE Transactions on Automatic Control*, 2024, 69(11): 7524 – 7539.
- [53] FENG H, LAVAEI J. Damping with varying regularization in optimal decentralized control. *IEEE Transactions on Control of Network Systems*, 2021, 9(1): 344 – 355.
- [54] FURIERI L, ZHENG Y, PAPACHRISTODOULOU A, et al. Sparsity invariance for convex design of distributed controllers. *IEEE Transactions on Control of Network Systems*, 2020, 7(4): 1836 – 1847.
- [55] TAKAKURA S, SATO K. Structured output feedback control for linear quadratic regulator using policy gradient method. *IEEE Transactions on Automatic Control*, 2023, 69(1): 363 – 370.
- [56] WENK C, KNAPP C. Parameter optimization in linear systems with arbitrarily constrained controller structure. *IEEE Transactions on Automatic Control*, 1980, 25(3): 496 – 500.
- [57] DEROO F. *Control of interconnected systems with distributed model knowledge*. Munich, Germany: Technische University München, 2016.
- [58] MA J, CHENG Z, LI X, et al. Data-driven linear quadratic optimization for controller synthesis with structural constraints. *IEEE Transactions on Cybernetics*, 2024, 54(4): 2295 – 2307.

- [59] YANG N, TANG J, LI Y, et al. Log-barrier search for structural linear quadratic regulators. *IEEE Transactions on Automatic Control*, 2024, 70(3): 1965 – 1972.
- [60] QIN Y, TANG S. Distributed sparse LQR control for power systems with Markov jump interconnection topologies. *IEEE Transactions on Circuits and Systems I: Regular Papers*, 2024, 72(7): 3655 – 3668.
- [61] MUKHERJEE S, VU T L. On distributed model-free reinforcement learning control with stability guarantee. *IEEE Control Systems Letters*, 2020, 5(5): 1615 – 1620.
- [62] BELBASI M R, BABAZADEH M. A scalable algorithm for distributed control of interconnected systems by graph decomposition. *IEEE Transactions on Control of Network Systems*, 2022, 10(2): 809 – 821.
- [63] VLAHAKIS E E, DRITSAS L D, HALIKIAS G D. Distributed LQR-based suboptimal control for coupled linear systems. *IFAC-PapersOnLine*, 2019, 52(20): 109 – 114.
- [64] BORRELLI F, KEVICZKY T. Distributed LQR design for identical dynamically decoupled systems. *IEEE Transactions on Automatic Control*, 2008, 53(8): 1901 – 1912.
- [65] NGUYEN D H, NARIKIYO T, KAWANISHI M, et al. Hierarchical decentralized robust optimal design for homogeneous linear multi-agent systems. *ArXiv Preprint*, 2016, ArXiv: 1607.01848.
- [66] VLAHAKIS E E, HALIKIAS G D. Distributed LQR methods for networks of non-identical plants. *IEEE Conference on Decision and Control (CDC)*. Miami Beach, FL: IEEE, 2018: 6145 – 6150.
- [67] JING G, BAI H, GEORGE J, et al. Decomposability and parallel computation of multi-agent LQR. *ArXiv Preprint*, 2021, arXiv: 2010.08615.
- [68] ALEMZADEH S, TALEBI S, MESBAHI M. Data-driven structured policy iteration for homogeneous distributed systems. *IEEE Transactions on Automatic Control*, 2024, 69(9): 5979 – 5994.
- [69] GORGES D. Distributed adaptive linear quadratic control using distributed reinforcement learning. *IFAC-PapersOnLine*, 2019, 52(11): 218 – 223.
- [70] FARJADNASAB M, BABAZADEH M. Model-free LQR design by Q-function learning. *Automatica*, 2022, 137: 110060.
- [71] YU J, HO D, WIEMAN A. Online adversarial stabilization of unknown networked systems. *Proceedings of the ACM on Measurement and Analysis of Computing Systems*, 2023, 7(1): 1 – 43.
- [72] OLSSON J, ZHANG R C, TEGLING E, et al. Scalable reinforcement learning for linear-quadratic control of networks. *American Control Conference (ACC)*. Toronto, Canada: IEEE, 2024: 1813 – 1818.
- [73] TALEBI S, ALEMZADEH S, MESBAHI M. Distributed model-free policy iteration for networks of homogeneous systems. *IEEE Conference on Decision and Control (CDC)*. Electr Network: IEEE, 2021: 6970 – 6975.
- [74] HUANG F, CAO M, WANG L. Approximate policy iteration for robust stochastic control of multi-agent Markov decision processes. *IEEE Transactions on Automatic Control*, 2025, 70(6): 3587 – 3602.
- [75] HUANG F, CAO M, WANG L. Learning enables adaptation in co-operation for multi-player stochastic games. *Journal of the Royal Society Interface*, 2020, 17(172): 20200639.
- [76] GUESTIN C, LAGOUKAKIS M, PARR R. Coordinated reinforcement learning. *International Conference on Machine Learning*. Sydney, Australia: Morgan Kaufmann Publishers, 2002: 227 – 234.
- [77] WANG T, ZENG L, DONG W, et al. Context-aware sparse deep coordination graphs. *International Conference on Learning Representations*. Online, 2021.
- [78] KAR S, MOURA J M, POOR H V, et al. QD-learning: A collaborative distributed strategy for multi-agent reinforcement learning through consensus + innovations. *IEEE Transactions on Signal Processing*, 2013, 61(7): 1848 – 1862.
- [79] ZHANG K, YANG Z, LIU H, et al. Fully decentralized multi-agent reinforcement learning with networked agents. *International Conference on Machine Learning*. Stockholm, Sweden: JMLR, 2018: 5872 – 5881.
- [80] ZHANG Y, ZAVLANOS M M. Cooperative multiagent reinforcement learning with partial observations. *IEEE Transactions on Automatic Control*, 2023, 69(2): 968 – 981.
- [81] RUAN J, DU Y, XIONG X, et al. GCS: Graph-based coordination strategy for multi-agent reinforcement learning. *International Conference on Autonomous Agents and Multiagent Systems*. Online: IFAAMAS, 2022: 1128 – 1136.
- [82] BOEHMER W, KURIN V, WHITESON S. Deep coordination graphs. *Proceedings of the 16th Conference on Uncertainty in Artificial Intelligence*. San Francisco, CA, USA: Association for Computing Machinery, 2020: 980 – 991.
- [83] KOLLER D, PARR R. Policy iteration for factored MDPs. *The 16th Conference on Uncertainty in Artificial Intelligence*. Stanford, California, USA: Morgan Kaufmann Publishers, 2000: 326 – 334.
- [84] NAYAK S, CHOI K, DING W, et al. Scalable multi-agent reinforcement learning through intelligent information aggregation. *International Conference on Machine Learning*. Honolulu, HI: JMLR, 2023: 25817 – 25833.
- [85] YUN W J, LIM B, JUNG S, et al. Attention-based reinforcement learning for real-time UAV semantic communication. *International Symposium on Wireless Communication Systems (ISWCS)*. Berlin, Germany: IEEE, 2021: 1 – 6.
- [86] LI S, GUPTA J K, MORALES P, et al. Deep implicit coordination graphs for multi-agent reinforcement learning. *International Conference on Autonomous Agents and Multiagent Systems*. Online: IFAAMAS, 2021: 764 – 772.
- [87] BIANCHI F, ZORZI E, CASTELLINI A, et al. Scalable safe policy improvement for factored multi-agent MDPs. *International Conference on Machine Learning*. Vienna, Austria: JMLR, 2024: 3952 – 3973.
- [88] CHU T, WANG J, CODECA L, et al. Multi-agent deep reinforcement learning for large-scale traffic signal control. *IEEE Transactions on Intelligent Transportation Systems*, 2020, 21(3): 1086 – 1095.
- [89] KOK J R, VLASSIS N. Using the max-plus algorithm for multiagent decision making in coordination graphs. *RoboCup 2005: Robot Soccer World Cup IX*. Osaka, Japan: Springer, 2006, 9: 1 – 12.
- [90] DU Y, LIU B, MOENS V, et al. Learning correlated communication topology in multi-agent reinforcement learning. *International Conference on Autonomous Agents and Multiagent Systems*. Online: IFAAMAS, 2021: 456 – 464.
- [91] CHEN D, CHEN K, LI Z, et al. Powernet: Multi-agent deep reinforcement learning for scalable powergrid control. *IEEE Transactions on Power Systems*, 2021, 37(2): 1007 – 1017.
- [92] PARK C, ZHANG K, OZDAGLAR A. Multi-player zero-sum Markov games with networked separable interactions. *Advances in Neural Information Processing Systems*. New Orleans, USA: PLMLR, 2023: 37354 – 37369.
- [93] ABDALLAH S, LESSER V. Multiagent reinforcement learning and self-organization in a network of agents. *International Joint Conference on Autonomous Agents and Multiagent Systems*. Honolulu Hawaii, USA: Association for Computing Machinery, 2007: 172 – 179.

- [94] ZHANG Y, QU G, XU P, et al. Global convergence of localized policy iteration in networked multi-agent reinforcement learning. *Proceedings of the ACM on Measurement and Analysis of Computing Systems*, 2023, 7(1): 1 – 51.
- [95] CHU T, CHINCHALI S, KATTI S. Multi-agent reinforcement learning for networked system control. *ArXiv Preprint*, 2020, arXiv: 2004.01339.
- [96] BERTSEKAS D. Multiagent reinforcement learning: Rollout and policy iteration. *IEEE/CAA Journal of Automatica Sinica*, 2021, 8(2): 249 – 272.
- [97] GRILLI J, BARABAS G, MICHALSKA-SMITH M J, et al. Higher-order interactions stabilize dynamics in competitive network models. *Nature*, 2017, 548(7666): 210 – 213.
- [98] BATTISTON F, CENCETTI G, IACOPINI I, et al. Networks beyond pairwise interactions: Structure and dynamics. *Physics Reports*, 2020, 874: 1 – 92.
- [99] WANG Y, LI A, WANG L. Networked dynamic systems with higher-order interactions: Stability versus complexity. *National Science Review*, 2024, 11(9): nwae103.

作者简介:

井冈山 博士, 教授, 研究方向为网络化系统的控制、优化与强化学习, E-mail: jinggangshan@cqu.edu.cn;

王 龙 博士, 教授, 研究方向为人工智能理论、演化博弈与群体决策、分布式优化、多机器人系统等, E-mail: longwang@pku.edu.cn;

史大威 博士, 教授, 研究方向为事件触发的感知、学习与控制、数据驱动轨迹规划与任务调度等, E-mail: daweishi@bit.edu.cn;

陈通文 博士, 教授, 研究方向为网络控制、过程控制以及多率数字信号处理, E-mail: tchen@ece.ualberta.ca.